SenseRDF: Towards a Linked Data Conversion Tool

A. Silva, N. França, B. Paulino, D. Souza and W. Travassos, *Member, Instituto Federal de Educação, Ciências e Teconologia da Paraíba - IFP*

Abstract— Underlying the development of the Semantic Web, the project Linked Data aims to define a set of best practices for publishing and connecting structured data on the Web with the purpose of creating a Web of Data. To this end, at first, existing data should be converted to a standard model in such a way that they can be understood by software agents and be used by diverse applications. In this light, the tool named SenseRDF has been developed to allow the conversion of data in formats such as PDF and XML to a representation model in RDF. The generated data (in RDF) follow the Linked Data principles and adhere to commonly accepted vocabularies.

Keywords — data conversion, Linked Data, vocabularies, RDF

I. INTRODUÇÃO

Internet contemporânea, nos moldes da World Wide A Web (ou simplesmente Web), vive um constante processo de evolução e tem revolucionado a forma como criamos conteúdo e trocamos informações. A Web organizou as informações na Internet por meio de hipertexto e tornou a interação do usuário com a rede mundial mais amigável. Entretanto, esses conteúdos publicados normalmente seguem regras apenas sintáticas, com objetivos de apresentação, não permitindo que se consiga extrair semântica dos mesmos, nem ligá-los, sem que para isso seja feito um grande esforço de implementação. Considerando isso, a Web atual pode ser classificada ainda como sintática e o processo de interpretação dos conteúdos disponibilizados fica a cargo dos usuários [1]. Diante dessa constatação, uma nova visão da Web vem sendo buscada e tem sido denominada de Web Semântica (Semantic Web) [2]. Os documentos na Web Semântica possuiriam, além das informações que descrevem a estrutura sintática do seu conteúdo, outras informações que dariam o entendimento semântico a esse conteúdo.

Como base ao desenvolvimento da Web Semântica, surgiu o projeto Linked Data que delimita um conjunto de práticas para publicar e conectar dados estruturados na Web, com o intuito de criar um espaço global de dados ou uma "Web de Dados" [3]. Estas práticas são fundamentadas em tecnologias Web, como HTTP (Hypertext Transfer Protocol) e URI (Uniform Resource Identifier), e no uso do modelo RDF (Resource Description Framework), com o objetivo de permitir a

leitura dos dados conectados semanticamente, de forma automática, por agentes de software.

Para aplicar essas práticas e alcançar a visão da *Web* de Dados, é necessário trabalhar com algumas etapas básicas: (i) conversão de dados disponíveis em formatos diversos, como, por exemplo, PDF, XML e HTML, em modelo de representação padrão RDF; (ii) associação dos objetos presentes nos diversos conjuntos de dados por meio de links; (iii) publicação dos conjuntos de dados na nuvem (*Linked Data Cloud*) [4] e o (iv) consumo dos dados publicados por meio de aplicações construídas para este fim.

Este trabalho abrange a primeira etapa do processo. Para viabilizar a publicação de dados no padrão Linked Data, a ferramenta SenseRDF vem sendo desenvolvida com o objetivo de converter dados atualmente em formatos PDF e XML em modelos RDF, seguindo os princípios propostos [4]. Para escolher os formatos a serem contemplados na primeira versão da ferramenta, fizemos um estudo dos dados atualmente disponibilizados no portal do governo brasileiro¹. Constatamos que boa parte deles se encontra em XML e PDF e que existem ainda poucas ferramentas que contemplam os mesmos [5]. Diante disso, a SenseRDF vem sendo implementada e, neste artigo, apresentamos a versão que converte arquivos PDF (seus metadados) em RDF. A ferramenta oferece um ambiente simples de ser utilizado e permite atualização dos metadados PDF, caso seja de interesse do usuário. Os dados (metadados) convertidos atendem aos princípios formulados no projeto Linked Data: (i) usa URIs para nomear recursos; (ii) utiliza vocabulários recomendados para identificar os recursos e (iii) permite que as URIs sejam acessadas através do protocolo HTTP.

Este trabalho está organizado da seguinte forma: a Seção 2 introduz a abordagem SenseRDF; a Seção 3 apresenta a ferramenta na prática por meio de exemplos; a Seção 4 descreve os trabalhos relacionados, e a Seção 5 tece algumas considerações e indica trabalhos futuros.

II. A ABORDAGEM SENSERDF

A sistemática para disponibilizar dados na Web, segundo o padrão *Linked Data*, envolve um processo no qual os dados de diferentes fontes são selecionados e depois convertidos para representações em um modelo padrão. Esta

-

¹ http://dados.gov.br/

conversão segue o conjunto de princípios estabelecidos, descritos resumidamente a seguir [4]: (i) o uso de URIs para identificação dos objetos/recursos; (ii) a utilização de tecnologias, como RDF² e SPARQL³, para descrição e consulta a estes recursos, respectivamente e (iii) o reaproveitamento de URIs, de forma que seja possível estabelecer ligações entre os dados disponíveis, com a finalidade de possibilitar a navegação por meio destas ligações.

Um desses princípios defende o uso de RDF como modelo de representação de dados estruturados na Web [6]. O RDF é um modelo de dados que descreve recursos ou objetos, ou seja, entidades que possuem uma identidade na web [6, 7]. Os recursos são descritos como uma tripla (S, P, O), interpretada como "S possui P com valor O", onde S é o sujeito da tripla, designado por um recurso, P é o predicado da afirmação, designado por um recurso e O é o objeto da afirmação, designado também por um recurso ou por um literal [7, 8]. Com o RDF, o uso de links e de vocabulários recomendados, é possível descrever significado sobre os objetos ou recursos. Mais especificamente, um link RDF pode ser uma tripla RDF em que o sujeito da tripla é uma referência URI no namespace de um conjunto de dados, enquanto o predicado e/ou objeto da tripla são referências URI apontando para o namespace de outro conjunto de dados. "Derreferenciando" essas URIs, produzimos descrição do recurso vinculado fornecido pelo servidor remoto. Essa descrição irá geralmente conter um link RDF adicional que aponta para outra URI que, por sua vez, pode ser também "derreferenciada". Isto é como a descrição de recursos individuais é tecida dentro da Web de Dados. Isto é também como a Web de Dados pode ser navegada usando um navegador Linked Data ou rastreado por um robô de um engenho de busca.

Dentro desse panorama, o objetivo da SenseRDF é permitir converter dados, a princípio PDF e XML, em modelo RDF, fazendo uso de informações do domínio dos dados e referenciando os termos dos vocabulários pertinentes a este domínio. A Figura 1 apresenta uma visão geral da arquitetura da ferramenta SenseRDF.

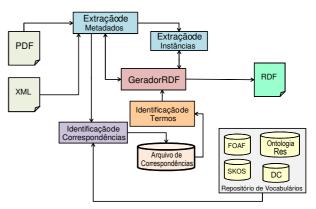


Figura 1. Arquitetura da Ferramenta SenseRDF

A ferramenta SenseRDF permite a conversão de dados em formato PDF e XML. Como forma de prover a semântica do domínio a partir de terminologias recomendadas (vocabulários), a ferramenta mantém um repositório de vocabulários, como, por exemplo, o FOAF⁴ e o DC⁵, além de ontologias de domínio que possam ser usadas como referência de termos.

Para a conversão, inicialmente a ferramenta identifica os metadados existentes na fonte de dados de entrada. metadados estes que podem ser de arquivos PDF ou XML. Um arquivo PDF contém metadados como Author e Title, já o XML pode conter diversos tipos que dependem do criador da fonte. Em seguida, a ferramenta gera um alinhamento de correspondências entre estes metadados e os termos (conceitos) existentes nos vocabulários recomendados. O objetivo do alinhamento é explicitar relações de similaridade entre os metadados da fonte de dados e os termos dos vocabulários existentes. Para os objetivos da ferramenta, estamos buscando relações de igualdade entre esses termos, para identificar o que pode ser referenciado dos vocabulários existentes. O alinhamento é persistido e, a cada novo arquivo a ser convertido, é verificado se a correspondência entre o metadado e o termo do vocabulário já existe. Caso não exista, ela é inserida neste arquivo de correspondências. Considerando arquivos PDF como fontes de dados, exemplos de correspondências de igualdade presentes no alinhamento são:

- Criador $\equiv dc$:creator
- Autor $\equiv res:author$

Onde Criador e Autor são metadados de um arquivo PDF, o prefixo *dc* é referente ao vocabulário DC (*Dublin Core*) e o prefixo *res* é referente a uma ontologia de domínio sobre autores de publicações.

Caso não haja nenhum termo de vocabulário equivalente a um metadado, este poderá ser adicionado a uma ontologia existente no repositório. Caso esta

² http://www.w3.org/RDF/

³ http://www.w3.org/TR/rdf-sparql-query/

⁴ http://www.foaf-project.org/

⁵ http://dublincore.org/documents/dcmi-terms/

ontologia não exista, ela será criada e armazenada no repositório para ser utilizada na geração/atualização de futuros alinhamentos e nas conversões subsequentes.

Depois de extraídos os metadados, as instâncias (indivíduos), no caso de arquivos XML, são também extraídas. A ferramenta, então, gera um arquivo RDF que contém os metadados referenciados por meio dos termos dos vocabulários e os objetos identificados provenientes das instâncias extraídas.

Um resumo dos componentes que fazem parte da arquitetura do SenseRDF é apresentado a seguir:

- Repositório de Vocabulários: repositório onde se encontram armazenados os vocabulários e ontologias de domínio que são utilizados pela ferramenta. Caso seja necessário, o usuário pode adicionar uma ontologia ou vocabulário específico de seu domínio.
- Arquivo de Correspondências: armazena o alinhamento obtido no processo de matching entre os metadados da fonte de dados e os termos dos vocabulários existentes.
- Extração de Metadados: extrai os metadados da fonte de dados escolhida pelo usuário.
- Extração de Instâncias: é usado no caso do usuário escolher uma fonte de dados XML. Este módulo extrai os dados (instâncias ou indivíduos) existentes na fonte de dados.
- Identificação de Correspondências: gera ou atualiza um alinhamento de correspondências entre os metadados da fonte de dados e os termos existentes nos vocabulários recomendados.
- Identificação de Termo do Vocabulário: usando as correspondências identificadas, este módulo referencia um metadado da fonte quanto ao seu termo correspondente no momento da geração do RDF.
- Geração RDF: módulo principal que recebe os termos identificados nas correspondências, os metadados e as instâncias da fonte de dados, gerando assim um RDF final.

III. A FERRAMENTA SENSERDF NA PRÁTICA

A ferramenta SenseRDF foi implementada em linguagem Java, utilizando as APIs Jena⁶, JDOM⁷, Itext⁸, *Alignment* API⁹ e OWL API¹⁰. A primeira versão da SenseRDF contempla todo o processo de conversão para arquivos PDF. A conversão é realizada sobre seus

metadados e um link para o arquivo é mantido. Como

A Figura 2 apresenta a interface da SenseRDF que mostra algumas de suas opções: (I) campo para identificação do arquivo (pode ser um arquivo em disco ou uma URL indicando o mesmo); (II) área de exibição dos metadados do arquivo, que podem ser alterados no caso de arquivos PDF (como mencionado, nem sempre os arquivos PDF originais possuem metadados); (III) opção de geração de RDF - o usuário pode escolher entre gerar o RDF em sintaxe XML ou em N3 e (IV) área onde será exibido o RDF gerado.

nem sempre um arquivo PDF é criado definindo os seus metadados (isso não é uma prática comum), a ferramenta permite que o usuário defina um conjunto mínimo de metadados para o arquivo em questão. O usuário pode atualizar os mesmos também. Nesta seção, apresentamos a ferramenta, de forma prática, por meio de exemplos, considerando arquivos PDF.

A Figura 2 apresenta a interface da SenseRDF que

⁶ http://jena.apache.org/

⁷ http://www.jdom.org/

⁸ http://api.itextpdf.com/

⁹ http://alignapi.gforge.inria.fr/align.html

¹⁰ http://owlapi.sourceforge.net/

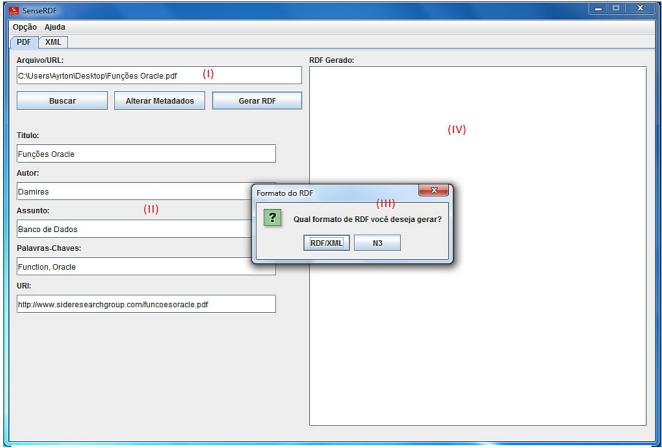


Figura 2. Interface da SenseRDF com algumas Opções

Como a ferramenta precisa das correspondências entre os metadados e os termos dos vocabulários, antes de gerar o RDF, ela cria ou atualiza o alinhamento existente.

Para isso, ela usa um processo de *matching* que faz uma análise linguística [9] e verifica a proximidade dos nomes dos metadados do arquivo PDF e os nomes dos termos dos vocabulários (diferença de apenas alguns caracteres, análise de possíveis radicais, etc). O alinhamento gerado é 1:1 e indica um grau de similaridade (medida de confiança) entre os elementos associados. Um fragmento do alinhamento de correspondências é mostrado como exemplo na Figura 3.

Dessa forma, quando um alinhamento é gerado ou atualizado, obtemos correspondências com diferentes níveis de similaridade. Isso é reportado através de uma medida de confiança. Neste exemplo, temos uma correspondência com medida igual a 1.0 que indica, com precisão, uma equivalência entre o metadado e o termo. A medida 0.86 indica um grau de similaridade muito alto. Realizando testes, percebemos que asjk correspondências com medida acima de 0.8 indicam equivalência entre os termos. Utilizamos então este *threshold*, para limiar a identificação das correspondências de equivalência. Assim, nesta versão, aquelas correspondências com

```
<map>
 <Cell>
   <entity1 rdf:resource='http://www.SideResearchGroup.com/ontologies/pdf/#Author'/>
   <entity2 rdf:resource='http://www.SideResearchGroup.com/ontologies/res#Author'/>
   <relation>=</relation>
   <measure rdf:datatype='http://www.w3.org/2001/XMLSchema#float'>1.0</measure>
 </Cell>
</map>
<map>
 <Cell>
   <entity1 rdf:resource='http://www.SideResearchGroup.com/ontologies/pdf/#ModDate'/>
   <entity2 rdf:resource='http://www.SideResearchGroup.com/ontologies/dc#date'/>
   <relation>=</relation>
   <measure rdf:datatype='http://www.w3.org/2001/XMLSchema#float'>0.863636363636363636</measure>
  </Cell>
</map>
```

Figura 3. Fragmento do Alinhamento obtido entre os Metadados e os Construtores dos Vocabulários.

threshold acima de 0.8 são definidas como equivalência entre o metadado e o termo.

Caso algum metadado não possua termo equivalente, a ferramenta solicita do usuário que selecione nos vocabulários existentes algum termo que possa ser usado (Figura 4). Se não existir um compatível, a ferramenta gera este novo termo adicionando o mesmo a uma ontologia no repositório. Para isso, o usuário marca que não encontrou nenhum termo correspondente ao metadado exibido. Este novo termo será adicionado a uma ontologia "othersTerms", que incorpora os termos que não pertencem aos vocabulários existentes. O usuário indica a que superclasse deve ser vinculada este novo termo ou conceito (subclasse).

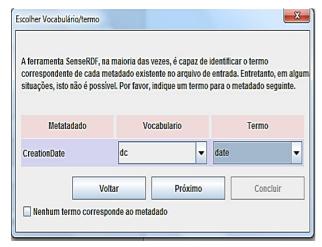


Figura 4. Seleção de Termos de Vocabulários para Correspondência com Metadados.

Para geração do RDF, a ferramenta lê o alinhamento de correspondências, para que sejam identificados os termos dos metadados da fonte. Com os metadados e termos de referência em mãos, de acordo com a opção de sintaxe RDF escolhida pelo usuário (RDF/XML ou N3), a ferramenta gera o RDF final, como mostrado na Figura 5 (em XML) e na Figura 6 (em N3).

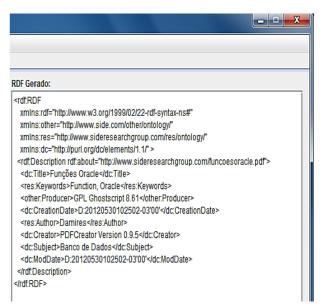


Figura 5. Exemplo de RDF gerado em Sintaxe XML.



Figura 6. Exemplo de RDF Gerado em sintaxe N3.

IV. TRABALHOS RELACIONADOS

Para a publicação de dados RDF, podem ser usadas ferramentas específicas de conversão. Atualmente, existem ferramentas para conversão de planilhas, arquivos CSV, dados relacionais e outros documentos [10]. Um exemplo é a ferramenta ConvertToRDF [11], desenvolvida pela MINDSWAP (Maryland Information and Network Dynamics Lab Semantic Web Agents Project) que tem como principal objetivo converter arquivos em formato XLS para RDF. A aplicação permite ao usuário executar o mapeamento através de uma ontologia própria da ferramenta, mas também permite o uso de outras ontologias para utilização nos mapeamentos. A ferramenta demonstra ser limitada na automação, uma vez que exige que o usuário faça todo o

mapeamento manualmente, sem possuir um repositório que armazene estes mapeamentos manuais, para que possa reutilizá-los mais tarde. Outro exemplo de ferramenta é A TopBraid Composer [5] que oferece editores gráficos visuais para RDF e diagramas de classe, incluindo a capacidade de gerar consultas SPARQL. Ela também permite a conversão automática de XML, XSD, Excel, UML e outras fontes de dados.

Há também o DBpedia [12], um projeto colaborativo que extrai dados do Wikipedia e os converte em dados estruturados usando o padrão RDF. O DBpedia está disponível, permitindo aos usuários utilizar e colaborar com o enriquecimento de seu repositório de datasets. A TripFS [13] é uma ferramenta que representa os diretórios e arquivos como recursos RDF. TripFS extrai metadados e cria links para outros conjuntos de dados e fornece um end-point SPARQL que permite aos clientes executar consultas sobre o sistema de arquivo inteiro. A Bio2RDF por outro lado converte documentos da área de biomedicina [14]. Visa também criar uma nuvem de dados sobre medicina. Lebo e Williams [15] apresentam uma abordagem para converter os dados CSV em Padrão Linked Data, de forma que permita melhoramentos incrementais. Aplicando esta abordagem, eles foram responsáveis por converter uma grande quantidade de dados governamentais dos EUA em RDF.

Apesar dos esforços e das ferramentas existentes, ainda existe uma demanda não atendida por serviços que facilitem o processo de conversão de dados, especialmente aqueles em formato PDF e XML. Em geral, as ferramentas se concentram no aspecto sintático da geração RDF, enquanto que a questão semântica, referente ao uso de anotações ou referências a mecanismos de controle terminológico (vocabulários), se torna incompleta. Diante disso, como forma de facilitar a conversão de dados no contexto brasileiro e buscando desenvolver uma solução que faça uso da semântica do domínio dos dados e dos padrões existentes, a ferramenta SenseRDF foi especificada e vem sendo desenvolvida.

Analisando nosso trabalho e comparando com os demais, destacamos que, ao converter os metadados PDF para RDF, nossa ferramenta, com o auxílio do usuário. identifica termos dos vocabulários existentes no repositório ou pode também criar novos termos, caso faça sentido ao domínio dos dados e não exista uma ontologia ainda para este domínio. Esta nova ontologia é persistida no repositório e será reutilizada em futuras conversões de arquivos que pertençam àquele domínio. O conjunto de ontologias e vocabulários existentes no repositório, juntamente com as correspondências já identificadas, automatiza futuras conversões e evita que o usuário tenha que fazer as correspondências entre metadados e termos de vocabulários manualmente. Assim, novas conversões serão mais rápidas e precisas. Nossa ferramenta também se diferencia por estar sendo desenvolvida de modo a permitir a conversão de dados disponibilizados pelo governo brasileiro em seu portal.

V. CONSIDERAÇÕES E TRABALHOS FUTUROS

Este trabalho apresentou a ferramenta de conversão de dados denominada SenseRDF. A SenseRDF provê um ambiente intuitivo e transparente onde o usuário escolhe formatos de fontes de dados que deseja converter para o modelo RDF segundo o padrão *Linked Data*. Para isso, a ferramenta utiliza um processo de *matching* que gera um alinhamento de correspondências entre os metadados da fonte e os termos existentes nos vocabulários do domínio dos dados. Utilizando estas correspondências, a SenseRDF gera o RDF, referenciando os termos identificados. O resultado pode ser obtido tanto em RDF/XML quanto no formato N3.

Nesta primeira versão, a ferramenta trabalha com dados no formato PDF, gerando o modelo RDF apenas com seus metadados. Encontra-se em andamento a implementação da opção de arquivos XML, que irá gerar o modelo RDF tanto para os metadados identificados quanto para as instâncias (indivíduos). Como trabalho futuro, a ferramenta será estendida para permitir a identificação de links entre dois conjuntos de dados RDF diferentes.

REFERÊNCIAS

- Costa A., Yamate F. 2009. Semantic Lattes: uma ferramenta de consulta baseada em ontologias. Trabalho de Graduação em Engenharia de Computação - Escola Politécnica. IME/USP.
- [2] Berners-Lee T., Hendler J., Lassilia O. 2001. The semantic web. Scientific American. 284(5):34–44, Mai 2001.
- [3] Bizer C., Heath T., Berners-Lee T. 2009. Linked data the story so far. *Int. J. Semantic Web Inf. Syst.* 5(3):1–22, 2009.
- [4] Heath, T., Bizer, C. 2011. Linked Data: Evolving the Web into a Global Data Space (1st edition). Synthesis Lectures on the Semantic Web: Theory and Technology, 1:1, 1-136. Morgan & Claypool, 2011.
- [5] TopBraid Documentation. Available at http://www.topquadrant.com/products/TB_Composer.html.
- [6] Klyne, G., Carroll, J. J., McBride, B. 2004. Resource description framework (RDF): Concepts and abstract syntax. DOI= http://www.w3.org/TR/rdf-concepts/
- [7] Lóscio, B., Cunha, D.; Souza, D. 2011. Linked Data: da Web de Documentos para a Web de Dados. Escola Regional Ceará, Maranhão e Piauí 2011. Teresina: ERCEMAPI. 2011, v. 1, p. 79-99.
- [8] Travassos W., Silva A., França N., Dantas R., Souza D. 2011. RDF, RDF(S) e OWL: Uma Análise Comparativa Visando Atingir o Padrão Linked Data. In: Anais Ciências Exatas e da Terra do VI Congresso de Pesquisa e Inovação da Rede Norte e Nordeste de Educação Tecnológica – CONNEPI. Pg. 413-423. Natal, RN.
- [9] Euzenat J., 2004. An API for ontology alignment. Proceedings of the International Semantic Web Conference (ISWC), pages 698– 712, 2004.
- [10] Auer, S., Dietzold, S., Lehmann, J., Hellmann, S., and Aumueller, D. 2009 Triplify: Light-weight linked data publication from

- relational databases. In Quemada, J., León, G., Maarek, Y. S., and Nejdl, W., editors, *Proceedings of the 18th international Conference on World Wide Web*, WWW 2009, Madrid, Spain, April 20-24, 2009, pages 621–630. ACM.
- [11] ConvertertoRDF Documentation. Available at http://www.w3.org/wiki/ConverterToRdf.
- [12] Kobilarov G., Bizer C., Auer S., Lehmann J. 2009. DBpedia A Linked Data Hub and Data Source for Web and Enterprise Applications. Web Semantics Science Services and Agents on the World Wide Web. Volume: 7, Issue: 3, Publisher: Elsevier, Pages: 154-165.
- [13] Schandl, B., & Popitsch, N. 2010. Lifting File Systems into the Linked Data Cloud with TripFS. 3° International Workshop on Linked Data on the Web, Raleigh, North Carolina, USA. DOI= http://eprints.cs.univie.ac.at/69/
- [14] Bio2RDF Documentation. Available at http://bio2rdf.org/
- [15] Ding, L., Lebo, T., Erickson, J. S., DiFranzo, D., Williams, G. T., Li, X., Michaelis, J., Graves, A., Zheng, J. G., Shangguan, Z., Flores, J., McGuinness, D. L., and Hendler, J. 2010. TWC LOGD: A Portal for Linked Open Government Data Ecosystems. In JWS special issue on semantic web challenge'10.